

HESAPLAMALI ANLAM BİLİM

Bağlamda Öğrenme (ICL): Benzer mi, Rastgele mi?

Türkçe İlkokul Matematik Problemlerinde (GSM8K-TR) 5-Shot Örnek Seçim
Stratejilerinin Model Başarısına Etkisi

Veri Kümesi: GSM8K-TR

Metrikler: Cosine Sim & McNemar

Modeller: Qwen 2.5 (3B & 1.5B)

Araştırma Soruları ve Temsil Türleri

Temel Motivasyon

Dil modellerine çok adımlı matematik problemleri çözdürülürken sunulan bağlam içi (in-context) örneklerin seçim yöntemi kritik bir etkendir. Bu çalışmada şu temel hipotezler test edilmiştir:

- Örnekleri tamamen **rastgele** seçmek yerine test sorusuna mantıksal olarak **en yakın** olanları seçmek doğruluğu artırır mı?
- Benzerlik aranırken ham soru metni yerine sorunun derin yapısal (anlamsal) temsillerini kullanmak fark yaratır mı?

Test Edilen 4 Semantik Seviye

Yakın komşuluk (retrieval) süreçlerinde test edilen 4 farklı girdi formatı şu şekildedir:

- **Ham Soru (Text):** Kelime düzeyinde yüzey benzerliği.
- **İşlem Yapısı:** Adım sayısı ve kullanılan operatör dizilimi.
- **Problem Şeması:** Senaryonun matematiksel arketipi.
- **Çözüm Deseni:** Problemin çözümünde izlenen mantıksal strateji.

Temsillerin Üretimi ve Prompt Kalibrasyonu

Problem metinlerindeki somut öğeler (örn: özel isimler, sayılar) anlamsal aramayı bozabilir. Bu amaçla **Gemini 2.5 Flash** ile içerikten arındırılmış soyut JSON yapıları üretilmiştir.

Prompt optimizasyon aşamasında, modelin çıktıya somut sayı sızdırma oranı (sızıntı) kontrol edilmiştir. Sisteme **"1-Shot" (tek örnekli)** bir şablon sunan v2 varyantı, formatı en iyi kavrayan ve sızıntıyı minimize eden sürüm olmuştur.

Prompt Tipi	Belirgin Farkı	Sızıntı Oranı
v1 (Temel)	Sadece Sistem Talimatı	%23.7
v2 (Kalibre)	Sistem + 1-Shot Örnek	%13.7
v3 (Yapısal)	Soyutlama Kuralı İlavesi	%27.9

// KAZANAN PROMPT ANATOMİSİ (v2 - Kalibre)

[System]: Sen bir matematik problemi sınıflandırma uzmanısın. Somut sayı, isim YAZMA. Soyutlamayı tutarlı yap.

[User - 1-Shot Örnek]:

ÖRNEK – Problem: 'Ali 3 elma aldı, 2 tane daha aldı...'
→ {"islem_yapisi": "iki adımlı, tek işlem (toplama)...",
"problem_semasi": "bir niceliğin ardışık artışı" ...}

[User - Asıl Soru]:


ŞİMDİ:

PROBLEM: {q}


SADECE şu JSON: { ... }

Model Sonuçları: 3B ve 1.5B Karşılaştırması

QWEN 2.5 - 3B MODELİ (% DOĞRULUK)



QWEN 2.5 - 1.5B MODELİ (% DOĞRULUK)



McNemar İstatistiksel Anlamlılık Testi Nedir?

Aynı veri seti üzerinde iki farklı yöntemin ürettiği sonuçları eşleştirerek karşılaştıran bir testtir. Aradaki doğruluk farkının rastlantısal (gürültü) mı yoksa gerçekten istatistiksel olarak **anlamlı mı** ($p < 0.05$) olduğunu ölçer.

Test Sonuçları:

- **3B Modeli:** Tüm farklar (Ham Soru vs Zero-shot $p=0.110$) **anlamsız (gürültü)** bulunmuştur.
- **1.5B Modeli:** En iyi temsil (Ham Soru) ile Zero-shot kıyaslandığında fark **ANLAMLI** ($p=0.037$) çıkmıştır. Yani zayıf modelde few-shot kullanmak kesinlikle işe yaramaktadır. Ancak örneklerin "rastgele" veya "benzer" seçilmesi arasındaki fark yine **anlamsızdır** ($p=0.105$).

Vaka Analizi 1: Yanıltıcı Benzerlik Tuzağı (3B)

SORU: Salı günü meyve satıcısı 2.5 düzine limon ve 5 düzine avokado satmıştır. Toplam meyve sayısı kaçtır? (Doğru Cevap: 90)

X İŞLEM YAPISI Yaklaşımı

Modele matematiksel işlem adımları benzeyen örnekler sunuldu. Model formül kalıbını körü körüne taklit ettiği için "düzineyi adede çevirme" mantığını atladi.

```
Çıktı: 2,5 düzine limon + 5 düzine avokado = 7,5 düzine  
meyve. Toplam meyve sayısı 7,5'tir.  
#### 7.5 (BAŞARISIZ)
```

✓ RASTGELE-5 Yaklaşımı

Modele tamamen alakasız (kraker, kitap okuma vb.) örnekler verildi. Model kalıp ezberleyemediği için kendi içsel mantığını devreye sokarak birimleri dönüştürdü.

```
Çıktı: 1 düzine = 12.  
2,5 * 12 = 30 limon. 5 * 12 = 60 avokado.  
Toplam: 30 + 60 = 90 meyve.  
#### 90 (BAŞARILI)
```

Vaka Analizi 2: Mantık Kopyalamanın Gücü (1.5B)

SORU: Willie 70 avro ile döndü. Kur 5 avro = 1 dolardır. Döviz bürosu resmi kurun 5/7'sini verecektir. Willie kaç dolar alır? (Doğru Cevap: 10)

✗ ZERO-SHOT Senaryosu

Küçük model, ardışık iki farklı oranlama/kesir adımını tek başına kurgulayamadı. Sayıları rastgele çarparak hatalı bir ondalık sonuca ulaştı.

```
Çıktı: 5 avro 1 dolar olduğu için 70 avro 7 dolar eder.  
Döviz bürosu 5/7 = 0.777 verir. 7 * 0.777 ...  
#### 5.44 (BAŞARISIZ)
```

✓ ÇÖZÜM DESENİ Senaryosu

Modele "ardışık kesir ve oran dönüşümü" içeren çözüm deseni benzeri komşular verildi. Model bu adımları başarıyla kopyalayarak doğru sonuca gitti.

```
Çıktı: 70 avro / 5 = 14 dolar (normal kur).  
Döviz bürosu kurun 5/7'sini verecek:  
14 * (5/7) = 10 dolar alacaktır.  
#### 10 (BAŞARILI)
```

Çalışmanın Temel Çıkarımları ve Değerlendirme

- **Büyük Ölçekli Modeller (3B+):** ICL süreçlerinde en yakın komşuyu (en benzer soruyu) aramak için harcanan işlem gücü çoğu zaman ekstra bir kazanç getirmez. Model içsel akıl yürütme yeteneğine sahiptir; hatta yanlış yapısal eşleşmeler modeli kalıp ezberine (Vaka 1'deki gibi) sürükleyebilir.
- **Küçük Ölçekli Modeller (1.5B):** Sıfır örnekle (Zero-shot) mantık kurmakta zorlanırlar. Ancak onlara herhangi bir örnek gösterildiğinde (few-shot) başarıları istatistiksel olarak kanıtlanmış bir şekilde artar ($p=0.037$). Yine de bu örneklerin soruya benzer veya rastgele seçilmesi sonucu genel ortalamada fazla etkilememektedir.
- **Format Güvenilirliği:** Modellerin matematik çözümlerinin sonuna **#### <cevap>** ayrıştırıcısını koymasını zorunlu kılmak, ölçüm doğruluğunu ve test güvenilirliğini ciddi oranda artırmıştır.