

Bağlamda Öğrenmede Örnek Seçim Stratejisinin Etkisi:

GSM8K-TR Üzerinde Benzer ve Rastgele 5-Atım Karşılaştırması

The Effect of Example Selection Strategy in In-Context Learning: Similar vs. Random 5-Shot on GSM8K-TR

Emre Beşik
Bilgisayar Mühendisliği Bölümü
Yıldız Teknik Üniversitesi
İstanbul, Türkiye
emre.besik@std.yildiz.edu.tr

Abstract—Bu çalışmada, büyük dil modellerinde bağlamda öğrenme (in-context learning) için 5-atımlı (5-shot) örnek seçim stratejisinin matematik problem çözme doğruluğu üzerindeki etkisi incelenmiştir. GSM8K-TR veri kümesi üzerinde, soruya en benzeyen örneklerin seçilmesi ile rastgele seçimin etkisi karşılaştırılmıştır. Benzerlik için her soru, ham metnine ek olarak içeriğinden arındırılmış üç soyut metinle (işlem yapısı, problem şeması, çözüm deseni) temsil edilmiştir. Bu soyut metinler, prompt optimizasyonu ile güçlü bir dil modeline üretilmiş ve turkish-e5-large modeliyle vektörleştirilmiştir. İki farklı ölçekteki çözücü model (Qwen2.5-3B ve Qwen2.5-1.5B) ile elde edilen sonuçlar, eşleştirilmiş McNemar testiyle değerlendirilmiştir. Bulgular, 5-atımlı öğrenmenin doğruluğu anlamlı olarak artırdığını ($p=0.037$), ancak örneklerin hangi temsile göre seçildiğinin genel doğruluğu istatistiksel olarak anlamlı düzeyde etkilemediğini göstermektedir.

Index Terms—bağlamda öğrenme, az-atımlı öğrenme, örnek seçimi, metin gömme, matematiksel akıl yürütme.

Abstract—This study investigates how the 5-shot example selection strategy in in-context learning affects mathematical problem-solving accuracy of large language models. On the GSM8K-TR dataset, selecting the most similar examples to a query is compared against random selection. For similarity, each question is represented not only by its raw text but also by three content-agnostic abstract texts (operation structure, problem schema, solution pattern), generated by a strong language model through prompt optimization and embedded with turkish-e5-large. Results from two solver models of different scale (Qwen2.5-3B and Qwen2.5-1.5B) are evaluated with the paired McNemar test. The findings show that 5-shot learning significantly improves accuracy ($p=0.037$), yet the representation used to select examples does not significantly affect accuracy.

I. GİRİŞ

Büyük dil modelleri, model ağırlıklarını güncellemeden, yalnızca prompt içine yerleştirilen örnekler aracılığıyla yeni görevleri öğrenebilir; bu yetenek bağlamda öğrenme olarak adlandırılır. Atımsız (zero-shot) kullanımda modele hiçbir örnek verilmezken, az-atımlı (few-shot) kullanımda görevi

tanımlayan çözülmüş örnekler gösterilir ve model hem görevi hem de cevap biçimini bu örneklerden çıkarır.

Few-shot örneklerinin *nasıl seçildiği* performansı etkileyebilir. Bir hipotez, soruya benzeyen örneklerin rastgele örneklerden daha faydalı olduğu yönündedir. Bu çalışmada, GSM8K-TR Türkçe matematik veri kümesi üzerinde, benzer örnek seçimi ile rastgele seçimi karşılaştırıyoruz. Ayrıca benzerliği tanımlamak için, sorunun yüzeysel içeriği yerine *türünü* ifade eden soyut temsiller kullanmanın katkısını inceliyoruz. Çalışmanın temel sorusu şudur: 5-atımlı örnekleri hangi tür metin benzerliğine göre seçmek doğruluğu en çok artırır?

II. İLGİLİ ÇALIŞMALAR

Az-atımlı öğrenme, GPT-3 ile geniş ölçekte gösterilmiştir [1]. Bilgi yoğun görevlerde geri-getirmeye dayalı yaklaşımlar, ilgili bağlamın seçilmesinin önemini ortaya koymuştur [2]. Bağlamda öğrenme için “iyi” örneklerin seçimi üzerine yapılan çalışmalar, sorguya anlamsal olarak yakın örneklerin seçilmesinin bazı görevlerde fayda sağladığını bildirmiştir [3]. Matematiksel akıl yürütme için yaygın kullanılan GSM8K veri kümesi [4], çok adımlı aritmetik problemler içerir. Metin gömmede E5 ailesi modelleri güçlü sonuçlar vermiştir [5]; bu çalışmada Türkçe için uyarlanmış turkish-e5-large kullanılmıştır.

III. YÖNTEM

A. Veri Kümesi

GSM8K-TR, GSM8K veri kümesinin Türkçeye çevrilmiş sürümüdür ve tek eğitim bölümünde 8792 soru içerir. Cevaplar serbest metin olduğundan, son sayısal cevabı güvenilir biçimde çıkaran bir ayıklayıcı ve çok cevaplı/belirsiz örnekleri eleyen bir filtre uygulanmıştır. Bu işlem sonucunda 7528 temiz örnek elde edilmiş; sabit tohum ile çakışmasız olarak 1500 örnek havuz (few-shot kaynağı) ve 300 örnek test kümesi ayrılmıştır.

B. Dört Temsil

Her soru, benzerlik araması için dört metinle temsil edilmiştir: (i) *ham soru*: sorunun kendi metni; (ii) *işlem yapısı*: adım sayısı ve aritmetik işlem türleri; (iii) *problem şeması*: senaryo arketipi; (iv) *çözüm deseni*: akıl yürütme stratejisi. Son üç temsil, sorunun içeriğinden (sayı, isim, nesne) bağımsız, soyut metinlerdir.

C. Soyut Temsillerin Üretimi ve Prompt Optimizasyonu

Soyut temsiller, güçlü bir dil modeline (Gemini Flash) ürettirilmiştir. Sistem komutu, modele problemi içeriğinden arındırıp yalnızca türünü tarif etmesini ve somut sayı/isim yazmamasını bildirir. Çıktı, üç alanlı JSON biçimindedir. Prompt seçimi için üç varyant; sızıntı oranı (tarife somut içerik kaçma oranı), geri-getirme tutarlılığı ve küçük bir doğrulama kümesindeki doğruluk metrikleriyle karşılaştırılmıştır (Tablo I). En yüksek doğruluk ve en düşük sızıntı oranı ile v2 (örnekle kalibre edilmiş) varyantı seçilmiştir.

Table I
PROMPT VARYANTLARININ KARŞILAŞTIRILMASI

Varyant	Doğruluk	Tutarlılık	Sızıntı
v1 (Temel)	%52.5	0.405	%23.7
v2 (Kalibre)	%55.0	0.359	%13.7
v3 (Yapısal)	%52.5	0.358	%27.9

D. Gömme ve Geri Getirme

Dört temsil de turkish-e5-large modeliyle vektörleştirilmiştir. E5 kuralına uygun olarak havuz tarafı "passage:", test tarafı "query:" öneki ile kodlanmış; vektörler L2-normalize edilmiş ve benzerlik kosinüs (iç çarpım) ile hesaplanmıştır. Her test sorusu için, her temsilde havuzdan en benzer 5 örnek seçilmiştir. Ayrıca benzerlik kullanmayan rastgele 5 örnek (sabit tohumlu) temel çizgi olarak oluşturulmuştur.

E. Çözücü Modeller ve Değerlendirme

Çözücü olarak Qwen2.5-3B-Instruct ve Qwen2.5-1.5B-Instruct modelleri kullanılmış; üretim deterministik (greedy) yapılmıştır. Few-shot örnekler, model ile aynı çıktı biçimini paylaşması için "#### <sayı>" satırıyla sonlandırılmıştır. Tahmin edilen son sayı altın cevapla karşılaştırılmıştır. Koşullar arası farkın anlamlılığı eşleştirilmiş McNemar testiyle değerlendirilmiştir.

IV. DENEYSEL SONUÇLAR

Farklı temsil stratejilerinin Qwen2.5-3B ve Qwen2.5-1.5B modelleri üzerindeki doğruluk oranları Tablo II'te verilmiştir.

Her iki modelde de en yüksek doğruluğu "ham soru" temsili vermiştir; ancak bu farklılıkların tesadüfi olup olmadığını ölçmek adına uygulanan McNemar istatistiksel anlamlılık testi sonuçları Tablo III'te detaylandırılmıştır.

Qwen2.5-3B modelinde, en iyi performansı gösteren ham soru tabanlı seçim ile atımsız kullanım ($p=0.110$) ve rastgele seçim ($p=0.120$) arasında istatistiksel olarak anlamlı bir fark bulunamamıştır. Buna karşın, Qwen2.5-1.5B modelinde ham

Table II
KOŞULLARA GÖRE DOĞRULUK (N=300)

Koşul	Qwen2.5-3B	Qwen2.5-1.5B
Atımsız (zero-shot)	%45.3	%18.0
Rastgele-5	%45.7	%20.0
Ham soru	%50.3	%24.3
İşlem yapısı	%47.7	%20.7
Problem şeması	%44.7	%21.0
Çözüm deseni	%46.0	%21.7

soru tabanlı 5-atımlı koşulun atımsız koşula göre üstünlüğü istatistiksel olarak anlamlıdır ($p=0.037$). Ancak, 1.5B modelinde de benzerlik tabanlı seçimin rastgele seçime karşı üstünlüğü ($p=0.105$) anlamlı bulunmamıştır.

Table III
MCNEMAR TESTİ SONUÇLARI (ANLAMLILIK EŞİĞİ $P<0.05$)

Karşılaştırma	p-değeri	Sonuç
Qwen2.5-3B		
Ham Soru vs Atımsız	0.110	Anlamsız
Ham Soru vs Rastgele	0.120	Anlamsız
Qwen2.5-1.5B		
Ham Soru vs Atımsız	0.037	Anlamlı
Ham Soru vs Rastgele	0.105	Anlamsız

V. TARTIŞMA

Elde edilen kantitatif bulgular iki kritik noktayı ortaya koymaktadır. Birincisi, az-atımlı (few-shot) öğrenme genel doğruluğu artırmaktadır ve bu etki özellikle daha küçük olan 1.5B modelinde istatistiksel olarak belirgindir. İkincisi, örneklerin *hangi* temsile göre seçildiği (benzer veya rastgele) doğruluğu genel ortalama istatistiksel olarak anlamlı düzeyde değiştirmemektedir. Bu sonuç, GSM8K-TR gibi veri kümelerinde az-atımlı öğrenmenin faydasının örneklerin anlamsal kimliğinden çok, modelin formatı ve biçimi tanımalarını sağlayan varlığından kaynaklandığını düşündürmektedir.

Niteliksel (vaka) incelemelerde ise model ölçekleri arasında ilginç davranış farklılıkları tespit edilmiştir. Benzerlik tabanlı seçimin (özellikle çözüm deseni), Qwen2.5-1.5B gibi küçük modellerde ardışık kesir ve oran/dönüşüm gibi belirli şablonlu sorularda mantık kopyalaması sağlayarak kazanç getirdiği görülmüştür. Ancak Qwen2.5-3B gibi nispeten daha büyük modellerde, aşırı yapısal benzerliğin bazen yanıltıcı olabildiği gözlenmiştir. Örneğin, birim dönüştürme gerektiren bir problemde (düzine hesabı), 'işlem yapısı' benzerliğiyle seçilen örneklerin modeli yalnızca ardışık adımları kopyalamaya (örüntü ezberine) iterek hatalı bir toplamaya yönelttiği saptanmıştır. Buna karşın 'rastgele' örnek seçiminin, modelin yapısal bir kalıba takılmasını engelleyerek kendi içsel mantığını (düzineyi adede çevirme işlemini) tetiklediği ve doğru sonuca ulaştırdığı gözlemlenmiştir. Bu durum, güçlü dil modellerinde aşırı spesifik anlamsal eşleştirmelerin modeli tembelleştirerek sahte korelasyonlara (spurious correlation) sürükleyebileceğini göstermektedir.

VI. SONUÇ

GSM8K-TR üzerinde, 5-atımlı örnek seçim stratejisinin etkisi incelenmiş; az-atımlı öğrenmenin doğruluğu anlamlı artırdığı, ancak örnek seçim biçiminin (benzer/rastgele/temsil) anlamlı bir fark yaratmadığı gösterilmiştir. Gelecek çalışmalarda daha büyük test kümeleri, farklı atım sayıları ve matematiksel yapıya duyarlı gömme yöntemleri incelenebilir.

REFERENCES

- [1] T. Brown *et al.*, “Language models are few-shot learners,” *Adv. Neural Inf. Process. Syst. (NeurIPS)*, 2020.
- [2] P. Lewis *et al.*, “Retrieval-augmented generation for knowledge-intensive NLP tasks,” *NeurIPS*, 2020.
- [3] J. Liu *et al.*, “What makes good in-context examples for GPT-3?,” *Proc. DeeLIO*, 2022.
- [4] K. Cobbe *et al.*, “Training verifiers to solve math word problems,” *arXiv:2110.14168*, 2021.
- [5] L. Wang *et al.*, “Text embeddings by weakly-supervised contrastive pre-training,” *arXiv:2212.03533*, 2022.
- [6] Qwen Team, “Qwen2.5 technical report,” *arXiv:2412.15115*, 2024.
- [7] Q. McNemar, “Note on the sampling error of the difference between correlated proportions or percentages,” *Psychometrika*, vol. 12, no. 2, pp. 153–157, 1947.
- [8] COSMOS AI Research Group, “gsm8k_tr,” Hugging Face, ytu-ce-cosmos/gsm8k_tr.
- [9] COSMOS AI Research Group, “turkish-e5-large,” Hugging Face, ytu-ce-cosmos/turkish-e5-large.